

Konverzačné porozumenie obrazu s LLaVA: Budovanie lokálneho vision-language chat asistenta s tool-use, agentickým routovaním a profilovaním výkonu

Arsenii Milenchuk, Nazarii Tymochko, Oleksandr Petsa, Dariia Shevchuk

Abstract—Tento článok sa zameriava na systematické porovnanie moderných Vision-Language modelov v úlohe konverzačného porozumenia obrázkov (Visual Question Answering). Pôvodný zámer analyzovať výlučne modely rodiny LLaVA bol rozšírený o ďalšie architektúry, vrátane modelov Gemma, Qwen-VL, MiniCPM-V a modelov založených na architektúre Mistral, s cieľom poskytnúť komplexnejší pohľad na ich správanie a výkonnosť. Experimenty boli realizované v prostredí lokálneho vyhodnocovania pomocou samostatných Jupyter notebookov pre každý model, pričom vstup tvorili páry (image, question) z VQA dátovej množiny. Výstupy modelov boli hodnotené pomocou metriky BERTScore (Precision, Recall a F1-skóre), čo umožnilo sémantické porovnanie generovaných odpovedí s referenčnými textami. Výsledky ukazujú, že veľkokapacitné modely, najmä Qwen-VL-30B, dosahujú najvyššiu kvalitu odpovedí, avšak za cenu výrazne vyšších výpočtových nárokov. Naopak, modely strednej a menšej veľkosti, ako MiniCPM-V, LLaVA-13B alebo Mistral-Small-3.1, predstavujú priaznivejší kompromis medzi kvalitou výstupov a efektívnosťou spracovania, čo ich robí vhodnejšími pre praktické nasadenie v prostrediach s obmedzenými zdrojmi. Článok poukazuje na absenciu univerzálne najlepšieho Vision-Language modelu a zdôrazňuje význam informovaného výberu modelu v závislosti od aplikačných požiadaviek [11].

Index Terms—vision-language modely, konverzačná AI, LLaVA, tool-use, Vision-RAG, OCR, retrieval, agentické routovanie, profilovanie výkonu, Docker, Chainlit

I. ÚVOD

VISION-LANGUAGE modely (VLM) umožňujú prirodzenú interakciu s vizuálnym obsahom kombináciou porozumenia obrazu a generovania textu. Podporujú úlohy ako vizuálne otázky a odpovede (VQA), identifikáciu a počítanie objektov, čítanie textových oblastí či viac-kolové dialógy ukotvené v obraze. Prechod od ukážky modelu k použiteľnému asistentovi však zvyčajne vyžaduje ďalšie inžinierske komponenty: robustnú konektorovú architektúru, reprodukovateľné nasadenie, nástroje na profilovanie výkonu a jasnú metodológiu hodnotenia.

V tomto projekte sa zameriavame na vytvorenie *chat asistenta o obrázkoch* so podporou tool-use a rozšíriteľnou architektúrou. Náš skorší mílnik sa sústredil na prípravu infraštruktúry a modulárneho rozhrania pre testovanie lokálnych LLM pomocou architektúry model-controller-view, pričom boli pripravené moduly pre OCR, lokálne vyhľadávanie a segmentáciu dokumentov, čo umožňuje budúcu integráciu

Vision-RAG [1]. Praktickým obmedzením identifikovaným v mílniku sú výpočtové požiadavky na spustenie veľkých multimodálnych modelov, keďže VLM s veľkosťou 7B-70GB často vyžadujú GPU s vysokou VRAM [1].

Pre praktické použitie integrujeme lokálny vývojový stack (web UI, dátová vrstva, lokálne objektové úložisko, inference adaptér) a terminálové monitorovanie na sledovanie spotreby CPU/GPU/RAM a životného cyklu aplikácie. Zároveň zavádzame agentické routovanie, ktoré explicitne riadi typ výstupu (iba text, iba bounding boxy alebo kombinácia), čo je dôležité pre vyhodnocovanie aj následné spracovanie.

Na základe konzultácií a priebežnej analýzy sme pôvodné zameranie na rodinu LLaVA rozšírili aj o ďalšie moderné Vision-Language architektúry, vrátane modelov Gemma, Qwen-VL a Mistral-based. Týmto rozšírením sme získali širší pohľad na vplyv architektúry a veľkosti modelu na kvalitu multimodálnych odpovedí v reálnych scenároch použitia [10].

Hlavné príspevky článku:

- Modulárna konektorová architektúra pre multimodálnych chat asistentov (model-controller-view) pripravená na modely typu LLaVA [1].
- Integrácia tool-use (OCR, retrieval, segmentácia) pre Vision-RAG-ready pipeline [1].
- Reprodukovateľný lokálny deployment stack (databáza, úložisko, UI, inference adaptér) s monitorovaním pre profilovanie výkonu.
- Scenárová evaluačná sada (chladnička, varenie, doprava, lokalizácia) a dokumentácia agentických routovacích režimov.

II. PREHĽAD LITERATÚRY

Moderné vision-language asistenty typicky kombinujú vision encoder s veľkým jazykovým modelom tak, aby podporovali inštrukčné učenie a viac-kolové dialógy nad obrazmi. V praxi musia takéto systémy riešiť nielen *sémantiku* (čo je v obraze a ako to súvisí s otázkou), ale aj *formát výstupu* (ako reprezentovať bounding boxy, extrahovaný text a pod.).

Významná línia práce rozširuje čisté VQA o retrieval-augmented generation (RAG) na ukotvenie odpovedí v externých zdrojoch. Vision-RAG tento princíp prenáša na multimodálne vstupy a často využíva tool-use moduly ako OCR, lokálny retrieval a výber segmentov. V našom projekte sú

Model InterVL využíva stratégiu *alignment-before-projection*, pri ktorej sú vizuálne reprezentácie najskôr zarovnané s jazykovým priestorom ešte pred samotnou projekciou do latentného priestoru jazykového modelu. Tento prístup umožňuje lepšiu sémantickú konzistenciu medzi vizuálnymi a textovými tokenmi a znižuje informačné straty pri multimodálnej fúzii.

Architektúra modelu pozostáva z výkonného vision encoderu a veľkokapacitného jazykového modelu, ktoré sú prepojené pomocou trénovaných multimodálnych mapovacích vrstiev. V porovnaní s modelmi typu LLaVA kladie InterVL väčší dôraz na kvalitu počítačného zarovnania modálnych reprezentácií, čo sa pozitívne prejavuje najmä v úlohách vyžadujúcich presné vizuálno-jazykové porozumenie.

Model InterVL-30B je však spojený s vyššími výpočtovými nárokmi, predovšetkým z hľadiska pamäte GPU a času inferencie, čo obmedzuje jeho praktické využitie v prostrediach s obmedzenými zdrojmi. Napriek tomu dosahuje stabilné a konkurencieschopné výsledky v konverzačných a VQA úlohách, čím predstavuje zaujímavý referenčný bod pre porovnanie s ostatnými veľkokapacitnými Vision-Language modelmi [12].

IV. METODOLÓGIA

A. Celková architektúra (Model–Controller–View)

Implementovali sme modulárny framework založený na architektúre model–controller–view, ktorý poskytuje jednotné rozhranie pre testovanie lokálnych LLM a multimodálnych modelov [1]. Vrstva modelu abstrahuje inferencie providerov, vrstva controller rieši formátovanie promptov a volanie nástrojov, a vrstva view zabezpečuje používateľské chat rozhranie a logovanie. Toto rozdelenie umožňuje pridávať ďalších providerov (vrátane VLM) s minimálnymi zásahmi do jadra.

B. Tool-use a pripravenosť na Vision-RAG

Komponenty tool-use sú implementované ako opakované použiteľné moduly vrátane OCR, lokálneho retrievalu a segmentácie dokumentov [1]. To umožňuje budúcu konštrukciu Vision-RAG pipeline, kde asistent: (i) analyzuje obraz alebo dokument, (ii) volá nástroje na extrakciu a vyhľadanie relevantného dôkazu a (iii) generuje odpoveď s odkazmi na vybrané segmenty. Metadáta experimentov a výstupy možno logovať a porovnávať medzi behmi [1].

C. Agentické routovanie a režimy výstupu

Pre konzistentné hodnotenie a následné spracovanie definujeme tri režimy vykonania:

- **TEXT_ONLY**: odpoveď obsahuje prirodzený text bez priestorových anotácií.
- **BBOX_ONLY**: odpoveď obsahuje bounding boxy (súradnice a štítky) s minimálnym alebo žiadnym naratívny textom.
- **TEXT_AND_BBOX**: kombinovaná odpoveď s textom aj bounding boxmi.

Agentické routovanie vyberá režim podľa požiadavky používateľa (napr. "zvýrazni zeleninu" vs "opíš scénu"), čím sa zabezpečí predvídateľná štruktúra výstupu. To tiež pomáha odhaliť routovacie nezhody (napr. očakávané BBOX_ONLY, ale systém vráti TEXT_AND_BBOX).

D. Monitorovanie a profilovanie

Na profilovanie výkonu a spotreby zdrojov bolo použité terminálové monitorovanie postavené na nástroji `tmux`. Rozloženie zahŕňalo:

- **bttop**: monitorovanie CPU, RAM a procesov,
- **nvtop**: sledovanie využitia GPU,
- panely s logmi aplikácie pre pozorovanie priebehu inferencie a agentického routovania.

Tento prístup umožnil reportovať špičkovú spotrebu VRAM, priemernú latenciu odpovedí a identifikovať výkonnostné bottlenecky. Monitorovanie bolo dôležité pri vyhodnocovaní správania systému na infraštruktúre HPC Perun [1].

E. Experimentálne prostredie

Experimenty boli realizované na infraštruktúre HPC Perun TUKE s využitím 1 node od H200 a to je - 128 GB VRAM, a taktiez na samostatnej grafickej karte NVIDIA RTX 4090. Táto konfigurácia poskytuje dostatočný výpočtový výkon a kapacitu VRAM na spúšťanie multimodálnych modelov triedy 7B, 30B, 70B, vrátane modelov typu LLaVA, Qwen, Inter-vl a td.

Použitie tejto platformy umožnilo stabilné vykonávanie inferencie, efektívne spracovanie obrazových vstupov a spoľahlivé testovanie agentického routovania a tool-use pipeline bez nutnosti agresívnej kvantizácie alebo redukcie modelu.

F. Dáta a prompty

Navrhujeme hodnotenie pomocou (i) COCO-inšpirovaného inštručného subsetu pre VQA promptovanie a (ii) kurátorskej sady scenárov so zameraním na priestorové uvažovanie a bounding box výstupy. Prompty sú formátované tak, aby explicitne vyžadovali konkrétny režim (TEXT_ONLY, BBOX_ONLY, TEXT_AND_BBOX) a testovali tool-use správanie (OCR, lokalizácia, počítanie).

G. Experimentálny workflow

Každý experiment prebiehal podľa jednotného postupu. Najprv bol zvolený konkrétny Vision-Language model a inicializovaný príslušný inference provider.

Následne boli postupne spúšťané scenárové prompty, ktoré pokrývali úlohy VQA, lokalizácie objektov, počítania a opisovania scén. Pre každý vstup bol zaznamenaný zvolený režim výstupu, čas spracovania a generovaná odpoveď.

Výstupy systému boli automaticky archivované a ukladané spolu s metadátami experimentu, čo umožnilo ich následnú analýzu a porovnanie medzi modelmi.



Fig. 4. Vstupný obrázok pre *Fridge Test*: scenár "foto chladničky" použitý na rozpoznávanie nápojov a objektov.

H. Vyhodnocovací pipeline

Na vyhodnotenie kvality odpovedí bol použitý automatizovaný vyhodnocovací pipeline založený na metrike BERTScore.

Pre každý generovaný výstup bola vypočítaná sémantická podobnosť s referenčnými odpoveďami pomocou metrík Precision, Recall a F1. Výpočty boli realizované v samostatných Jupyter Notebookoch pre jednotlivé modely.

Výsledné skóre bolo agregované naprieč scenármi, čo umožnilo objektívne porovnanie výkonnosti rôznych architektúr.

V. VÝSLEDKY

A. Scenárové kvalitatívne hodnotenie

Dokumentujeme sadu scénárových testov, ktoré simulujú reálne používateľské interakcie a benchmarkové úlohy:

1) *Fridge Test*: Bežný "fridge photo" scenár hodnotí rozpoznávanie a počítanie položiek pri požiadavke na textový výstup aj anotované bounding boxy. Typickým zlyhaním je nepresné počítanie/lokalizácia vizuálne podobných objektov (napr. citrus). Na Obr. 4 je vstupná fotografia a na Obr. 5 je výstup systému s bounding boxami. Obr. 6 dokumentuje agentické routovanie, kde sa najprv identifikujú kandidátne entity a následne sa zvolí režim výstupu (TEXT_AND_BBOX).

2) *Gotou Test*: Sanity-check na overenie, že model "vidí" obraz a dokáže lokalizovať špecifickú textovú oblasť. Tento test odhaľuje routovacie nezhody, keď sa očakáva BBOX_ONLY, no systém vráti TEXT_AND_BBOX.

3) *Hogo Test*: Scenár kuchynského asistenta (hot pot) testuje opis scény, generovanie receptu, zvýraznenie ingrediencií a detekciu iba zeleniny. Pozorovaná nekonzistencia môže




Fig. 5. Výstup asistenta v režime **TEXT_AND_BBOX**: identifikované nápoje s vizuálnym ukotvením pomocou bounding boxov.

nastať, keď text tvrdí neprítomnosť ingrediencie, ale bounding boxy ju napriek tomu označia (napr. vajcia).

4) *Meerkats Test*: Test s obrazom surikát bol zameraný na lokalizáciu špecifických častí objektov, konkrétne hláv jednotlivých zvierat. Úloha predstavuje jednoduchší scenár, ktorý umožňuje overiť schopnosť modelu presne identifikovať viacnásobné inštancie rovnakého objektu v jednej scéne.

Na Obr. 7 je zobrazený vstupný obraz, na Obr. 8 výstup systému s presnou lokalizáciou hláv jednotlivých jedincov. Obr. 9 dokumentuje proces výberu režimu výstupu a generovania anotácií.

B. Vyhodnotenie experimentov

Na vyhodnotenie kvality generovaných odpovedí sme použili metriku BERTScore, ktorá meria sémantickú podobnosť medzi referenčnými a generovanými textami pomocou metrík Precision, Recall a F1. BERTScore bol vybraný kvôli svojej odolnosti voči parafrázovaniu a vhodnosti pre otvorené odpovede VQA.

Tabuľka I sumarizuje výsledky jednotlivých testovaných Vision-Language modelov.

Najlepšie výsledky dosiahli modely Qwen-VL-30B a Qwen-VL-8B, ktoré vykazovali najvyššie hodnoty metriky F1, čo naznačuje ich schopnosť generovať sémanticky presné a konzistentné odpovede v komplexných vizuálno-jazykových úlohách.

Model InterVL-3.5-30B dosiahol konkurencieschopné výsledky (Precision = 0.5409, Recall = 0.4739, F1 = 0.5052), čím sa zaradil medzi výkonnejšie veľkokapacitné modely. Jeho výkon však bol dosiahnutý za cenu vyšších výpočtových nárokov, pričom čas inferencie dosahoval približne 69 minút,




Fig. 6. Ukážka konverzácie a interného routovania: systém najprv extrahuje kandidátne entity (napr. "cucumber water", "milk", "orange juice") a následne generuje textový výstup spolu s anotáciami.




Fig. 7. Vstupný obrázok pre *Meerkats Test*: skupina surikát v prirodzenom prostredí.

čo môže obmedzovať jeho praktické nasadenie v lokálnych alebo časovo citlivých aplikáciách.




Fig. 8. Výstup systému v režime **BBOX_ONLY**: lokalizácia hláv surikát pomocou bounding boxov.




Fig. 9. Ukážka konverzácie a agentického routovania pri úlohe lokalizácie objektov.

Modely Mistral-Small-3.1 a MiniCPM-V dosiahli vyvážený pomer medzi kvalitou výstupov a výpočtovou efektívnosťou, čo ich robí vhodnými kandidátmi pre lokálne nasadenie a praktické systémy s obmedzenými hardvérovými zdrojmi.

Modely rodiny LLaVA dosiahli stabilné, avšak mierne nižšie výsledky, pričom verzia LLaVA-13B prekonala menší variant LLaVA-7B. Variant BakLLaVA vykazoval výrazne nižšiu presnosť, čo naznačuje obmedzenú schopnosť generalizácie v testovaných scenároch.

Model LLaVA-Phi-3 dosiahol nízke skóre, čo poukazuje na slabšiu integráciu vizuálnych a jazykových reprezentácií pri komplexných úlohách VQA.

Pri modeli LLaMA-3.2-Vision-11B sa vyskytli anomálie

TABLE I
VÝSLEDKY HODNOTENIA POMOCOU BERTSCORE

Model	Precision	Recall	F1
LLaVA-13B	0.4903	0.4122	0.4485
LLaVA-7B	0.4638	0.4002	0.4298
BakLLaVA	0.2078	0.2009	0.2032
Gemma-12B	0.4136	0.3871	0.3984
Gemma-27B	0.4773	0.4250	0.4494
LLaVA-Phi-3	0.0579	0.1828	0.1116
MiniCPM-V	0.4757	0.4507	0.4605
Ministral-3-14B	0.3032	0.3751	0.3364
Mistral-Small-3.1	0.5243	0.4726	0.4967
Qwen-VL-30B	0.5921	0.5249	0.5562
Qwen-VL-8B	0.5853	0.5194	0.5501
InterVL-3.5-30B	0.5409	0.4739	0.5052




Fig. 10. Závislosť metrick Precision a Recall od veľkosti modelu (počet parametrov).

pri výpočte BERTScore z dôvodu generovania prázdnych alebo neplatných odpovedí, čo viedlo k záporným hodnotám metrick, a preto nebol tento model zahrnutý do kvantitatívneho porovnania.

Okrem Vision-Language modelov bol experimentálne testovaný aj model DeepSeek-LLM s 70 miliardami parametrov. Keďže ide o čisto jazykový model bez vizuálneho enkodéra, nebol schopný analyzovať obrazový vstup a generoval odpovede založené iba na pravdepodobnom odhade obsahu. Z dôvodu veľmi nízkych hodnôt hodnotiacich metrick nebol tento model ďalej zahrnutý do experimentálneho vyhodnotenia.

Celkovo výsledky potvrdzujú, že väčšie a architektonicky pokročilejšie modely dosahujú vyššiu presnosť, avšak za cenu vyšších hardvérových a časových nárokov.

C. Vzťah medzi veľkosťou modelu, výkonom a výpočtovým časom

Okrem absolútnych hodnôt metrick sme analyzovali aj vzťah medzi veľkosťou modelu (počet parametrov), presnosťou predikcií a výpočtovou náročnosťou.

Na Obr. 10 je znázornená závislosť metrick Precision a Recall od veľkosti modelu. Modely Qwen-VL dosahovali najvyššie hodnoty presnosti aj úplnosti, čo potvrdzuje pozitívny vplyv väčšej kapacity modelu na kvalitu generovaných odpovedí.




Fig. 11. Závislosť F1-skóre a výpočtového času od veľkosti modelu.

Naopak, menšie modely ako LLaVA-Phi-3 a BakLLaVA vykazovali nižšie hodnoty výkonu, čo naznačuje obmedzenú schopnosť reprezentovať komplexné vizuálno-jazykové vzťahy.

Obr. 11 zobrazuje vzťah medzi F1-skóre, veľkosťou modelu a výpočtovým časom inferencie. Najvyváženejší pomer medzi presnosťou a úplnosťou dosiahli modely Qwen-VL-30B a Qwen-VL-8B.

Z hľadiska výpočtovej náročnosti dosahovali najkratší čas menšie modely, najmä LLaVA-Phi-3. Naopak, model Mistral-Small-3.1 vykazoval najvyššie výpočtové nároky, čo môže limitovať jeho použitie v časovo citlivých aplikáciách.

Výsledky potvrdzujú existenciu kompromisu medzi presnosťou, veľkosťou modelu a výpočtovým časom, ktorý je potrebné zohľadniť pri praktickom nasadení systému.

D. Typické zlyhania

Naprieč scenármi sa objavujú najmä:

- **Chyby v počítaní:** vizuálne podobné objekty sa počítajú menej spoľahlivo.
- **Routovacie nezhody:** zvolený režim výstupu nemusí zodpovedať zámeru promptu.
- **Nekonzistencia text-bbox:** objekty sa objavujú v boxoch, ale text ich vynecháva alebo si odporuje.

Z hľadiska pomeru kvality a výpočtovej náročnosti sa ukázalo, že modely Qwen-VL poskytujú najvyššiu presnosť, avšak vyžadujú výrazné hardvérové zdroje.

Naopak, modely MiniCPM-V a Mistral-Small-3.1 predstavujú vhodný kompromis medzi výkonom, pamäťovou náročnosťou a latenciou, čo ich predurčuje pre praktické lokálne nasadenie.

Modely rodiny LLaVA sú vhodné najmä pre prototypovanie a základné experimenty, kde je prioritou stabilita a dostupnosť pred maximálnou presnosťou.

Tieto zistenia potvrdzujú, že výber vhodného Vision-Language modelu závisí nielen od dosahovanej presnosti, ale aj od dostupných výpočtových zdrojov a cieľového scenára použitia.

VI. ZÁVER

V práci sme predstavili architektúru lokálneho konverzačného vision-language asistenta navrhnutého na in-

tegráciu moderných multimodálnych modelov do modulárneho frameworku typu model–controller–view. Systém podporuje tool-use moduly (OCR, retrieval, segmentácia), agentické routovanie pre predvídateľné formáty výstupu, kontajnerizované nasadenie pre reprodukovateľnosť a terminálové monitorovanie pre detailné profilovanie výkonu.

HPC Perun TUKE s využitím 1 node od H200 a to je - 128 GB VRAM, a taktiez na samostatnej grafickej karte NVIDIA RTX 4090 potvrdili, že navrhnutý systém umožňuje stabilné a efektívne nasadenie Vision-Language modelov triedy 7B a vyššej bez nutnosti výraznej optimalizácie alebo kvantizácie. Výsledky scenárového hodnotenia zároveň ukázali, že agentické routovanie a jednotná architektúra výrazne zjednodušujú testovanie a porovnávanie rôznych modelových konfigurácií.

Navrhnutý framework predstavuje praktickú platformu pre výskum a prototypovanie multimodálnych asistentov, ktorá je vhodná nielen pre akademické experimenty, ale aj pre potenciálne nasadenie v aplikačných doménach ako vizuálne vyhľadávanie, dokumentová analýza alebo inteligentné monitorovacie systémy.

Budúca práca zahŕňa plnohodnotné spustenie vybraných Vision-Language modelov na infraštruktúre DGX, systematický benchmarking pomocou štandardizovaných VQA metrík, ďalší refinement agentického routovania a rozšírenie Vision-RAG pipeline o pokročilé mechanizmy dôkazového ukotvenia a automatickej validácie odpovedí.

POĎAKOVANIE

Ďakujeme konzultantovi prof. Ing. Peter Sinčák, CSc. za vedenie a spätnú väzbu a TUKE infraštruktúrnym tímom za podporu a prístup k výpočtovým zdrojom.

REFERENCES

- [1] A. Milenchuk, N. Tymochko, O. Petsa, and D. Shevchuk, “Vision-Language Chat Assistant s LLaVA: Skúsenosti a plán práce,” tretí milník, TUKE, Nov. 2025.
- [2] LLaVA Hugging Face repository, “llava-hf/llava-1.5-7b-hf.” [Online]. Available: <https://huggingface.co/llava-hf/llava-1.5-7b-hf>
- [3] Projektový repozitár (qwen-app). [Online]. Available: https://github.com/Nazar1119/Deep_Learning_2/tree/main/qwen-app
- [4] Dokumentácia scenárov (qwen-app/docs). [Online]. Available: https://github.com/Nazar1119/Deep_Learning_2/tree/main/qwen-app/docs
- [5] “Fridge test,” obj-det-chat-qwen3-vl documentation. [Online]. Available: https://github.com/sidjik/obj-det-chat-qwen3-vl/blob/master/docs/test_fridge.md
- [6] “Gotou test,” obj-det-chat-qwen3-vl documentation. [Online]. Available: https://github.com/sidjik/obj-det-chat-qwen3-vl/blob/master/docs/test_gotou.md
- [7] “Hogo test,” obj-det-chat-qwen3-vl documentation. [Online]. Available: https://github.com/sidjik/obj-det-chat-qwen3-vl/blob/master/docs/test_hogo.md
- [8] “Meerkats test,” obj-det-chat-qwen3-vl documentation. [Online]. Available: https://github.com/sidjik/obj-det-chat-qwen3-vl/blob/master/docs/test_meerkats.md
- [9] “Road test,” obj-det-chat-qwen3-vl documentation. [Online]. Available: https://github.com/sidjik/obj-det-chat-qwen3-vl/blob/master/docs/test_road.md
- [10] A. Antol et al., “VQA: Visual Question Answering,” in Proc. IEEE International Conference on Computer Vision (ICCV), pp. 2425–2433, 2015.
- [11] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, “BERTScore: Evaluating Text Generation with BERT,” in Proc. International Conference on Learning Representations (ICLR), 2020.

- [12] B. Lin, Y. Ye, B. Zhu, J. Cui, M. Ning, P. Jin, and L. Yuan, “InterVL: Scaling up Vision-Language Models with Interleaved Image-Text Data,” arXiv preprint arXiv:2312.00638, 2023.