


Modely typu Vision–Language Models (VLM) zohrávajú kľúčovú úlohu vo vývoji multimodálnych systémov, pretože kombinujú vizuálne vnímanie s jazykovým modelovaním, čo zabezpečuje prirodzenejšiu interakciu človeka s vizuálnymi údajmi. Tieto modely sa používajú na riešenie ťažkých vizuálnych otázok a odpovedí (VQA), generovanie popisov obrázkov, lokalizáciu objektov a vedenie viackrokových dialógov viazaných na vizuálny kontext. Prechod od samostatného modelu k prakticky použiteľnému systému vyžaduje nielen efektívnu architektúru, ale aj jasne definovanú metódu hodnotenia a systematické porovnávanie rôznych prístupov [1].

Jedným z najznámejších predstaviteľov tohto smeru je model LLaVA (Large Language and Vision Assistant), ktorý integruje vizuálny enkóder s veľkým jazykovým modelovacím backbonom a využíva inštrukčné učenie na podporu dialógovej interakcie nad obrázkami. Napriek vysokej výkonnosti LLaVA, súčasné výskumy ponúkajú alternatívne architektúry Vision-Language s rôznymi jazykovými modelmi a mechanizmami zosúladowania modalít, čo robí ich komparatívnu analýzu nevyhnutnou na zistenie výhod a obmedzení každého prístupu [1], [2].

V tejto práci sa zameriavame na systematické porovnanie viacerých moderných Vision-Language modelov v úlohe konverzačného porozumenia obrázkov. Pôvodným cieľom bolo analyzovať výlučne modely rodiny LLaVA v kontexte praktického nasadenia, avšak po konzultácii bol rozsah práce rozšírený o ďalšie modely, ako sú Gemma, Qwen-VL, MiniCPM-V a Mistral-based architektúry. Hodnotenie je založené na metrikách BERTScore (Precision, Recall a F1-skóre), ktoré umožňujú sémantické porovnanie generovaných odpovedí, a doplnené o analýzu výpočtovej náročnosti.

V práci bol použitý otvorený multimodálny dataset Visual Question Answering (VQA), dostupný na platforme Kaggle, ktorý kombinuje obrázky z prirodzenými jazykovými otázkami a odpoveďami. Dataset je určený na výskum úlohy Visual Question Answering, ktorá vyžaduje súčasné pochopenie vizuálneho obsahu a sémantiky textovej požiadavky. Každá vzorka obsahuje trojicu (obrázok, otázka, odpoveď), čo umožňuje hodnotiť schopnosť modelov Vision-Language integrovať informácie z rôznych modalít a generovať správne textové odpovede. Použitie tohto dátového súboru poskytuje jednotný základ pre komparatívnu analýzu rôznych architektur VLM v úlohách vizuálneho a jazykového porozumenia.



Cieľom tejto úlohy bolo analyzovať schopnosti modelov typu **Vision-Language** pri riešení úloh konverzačného porozumenia obrázkov, so zameraním na rodinu modelov **LLaVA (Large Language and Vision Assistant)**. Model **LLaVA** kombinuje **vizuálny enkóder s veľkým jazykovým modelom (LLM)**, čo mu umožňuje viesť prirodzený dialóg založený na vizuálnom obsahu. Pôvodným cieľom práce bolo využitie výlučne modelov **LLaVA** a návrh **používateľského rozhrania (UI)**, avšak po konzultácii bolo rozhodnuté presunúť dôraz z implementácie UI na rozšírenie experimentu o väčší počet **Vision-Language modelov** s cieľom ich systematického porovnania.

V prvej fáze **experimentu** boli analyzované viaceré varianty rodiny **LLaVA [3]**, ktoré sa líšia veľkosťou, architektúrou a použitým jazykovým modelom:


- LLaVA-7B** – základná verzia modelu LLaVA s menším počtom parametrov, navrhnutá pre efektívne experimentovanie a rýchle spracovanie.
- LLaVA-13B** – rozšírená verzia s väčšou kapacitou jazykového modelu, ktorá poskytuje lepšie jazykové porozumenie a detailnejšie odpovede.
- BakLLaVA** – alternatívna implementácia modelu LLaVA, zameraná na experimentálne úpravy architektúry a tréningového postupu.
- LLaVA-Phi-3** – ľahká verzia modelu LLaVA využívajúca jazykový model Phi-3, optimalizovaná na nižšie výpočtové nároky.

Výstupy jednotlivých modelov boli hodnotené pomocou metriky **BERTScore (Precision, Recall a F1-skóre)**, čo umožnilo sémantické porovnanie generovaných odpovedí s referenčnými textami.

S cieľom rozšíriť porovnanie aj mimo rodiny **LLaVA** boli do experimentu zahrnuté ďalšie moderné **Vision-Language modely** reprezentujúce rôzne architektonické prístupy:

Language Response


X_a



Gemma-12B – stredne veľký Vision-Language model zameraný na vyvážený pomer medzi kvalitou výstupov a výpočtovou náročnosťou.


Gemma-27B – väčší variant modelu Gemma, ktorý poskytuje vyššiu jazykovú a sémantickú kapacitu pri spracovaní vizuálnych vstupov.

Qwen-VL-8B – efektívny Vision-Language model optimalizovaný pre rýchle spracovanie a nižšie výpočtové nároky. **Qwen-VL-30B** – veľkokapacitný model určený na dosahovanie vysokej kvality odpovedí v komplexných vizuálno-jazykových úlohách [5].



MiniCPM-V – kompaktný Vision-Language model optimalizovaný pre efektívne využitie výpočtových zdrojov.
Ministral-3-14B – model založený na architektúre Mistral, ktorý predstavuje kompromis medzi veľkosťou a kvalitou generovaných odpovedí [4].
Mistral-Small-3.1 – pokročilý model z rodiny Mistral zameraný na vysokú presnosť a robustné jazykové spracovanie.

Aj v tomto prípade bol pre každý model vytvorený samostatný **Jupyter Notebook** a jeho výstupy boli následne hodnotené pomocou metriky **BERTScore**.

[illegible]

Najvyššie hodnoty presnosti dosahuje model **Qwen3-VL**, čo naznačuje jeho schopnosť produkovať presnejšie predikcie. Naopak, model **LLaVA-Phi3** vykazuje najnižšie hodnoty presnosti, čo poukazuje na vyšší podiel nesprávnych predikcií.

Z hľadiska metriky Recall dosahuje najlepšie výsledky **Qwen3-VL**, keďže identifikuje najväčší podiel relevantných prípadov. Najnižšie hodnoty Recall boli zaznamenané pri modeli **LLaVa-Phi3**, čo poukazuje na jeho obmedzenú schopnosť zachytiť všetky relevantné vzorky.

Najvyšší F1-skóre dosahuje model **Qwen3-VL**, čo potvrdzuje jeho vyvážený pomer medzi presnosťou a úplnosťou. Najnižšie hodnoty F1-skóre vykazuje **LLaVA-Phi3**, čo naznačuje celkovo slabší výkon tohto modelu.


Najkratší čas výpočtu dosahuje model **LLaVA-Phi3**, čo je dané jeho menším počtom parametrov. Naopak, **Mistral-Small 3.1** vykazuje najvyššie výpočtové nároky, čo obmedzuje jeho použitie v časovo citlivých aplikáciách.

V tejto práci sme sa zamerali na porovnanie moderných **Vision-Language modelov** v úlohe konverzačného porozumenia obrázkov. Pôvodný zámer analyzovať výlučne modely rodiny **LLaVA** bol rozšírený o ďalšie architektúry, vrátane modelov **LLaVA-7B**, **LLaVA-13B**, **BakLLaVA**, **LLaVA-Phi-3**, ako aj modelov z rodín **Gemma (Gemma-12B, Gemma-27B)**, **Qwen-VL (Qwen-VL-8B, Qwen-VL-30B)** a modelov založených na architektúrach **MiniCPM** a **Mistral (MiniCPM-V, Ministral-3-14B, Mistral-Small-3.1)**. Cieľom bolo poskytnúť komplexnejší pohľad na ich správanie a výkonnosť.

Experimentálne výsledky založené na metrike **BERTScore (Precision, Recall, F1-skóre)** potvrdzujú, že najvyššiu celkovú kvalitu odpovedí dosahujú veľké **Vision-Language modely** z rodiny **Qwen**. Model **Qwen-VL-30B** vykazuje najlepšie hodnoty **Precision = 0.5921, Recall = 0.5249 a F1-skóre = 0.5562**, pričom veľmi blízke výsledky dosahujú aj menší variant **Qwen-VL-8B (Precision = 0.5853, Recall = 0.5194, F1-skóre = 0.5501)**. Tieto výsledky poukazujú na vysokú schopnosť modelov **Qwen-VL** zachytávať **sémantické vzťahy** medzi **vizuálnym a textovým obsahom**.

Medzi modelmi strednej veľkosti dosahuje najlepšie výsledky **Mistral-Small-3.1**, ktorý vykazuje **Precision = 0.5243, Recall = 0.4726 a F1-skóre = 0.4967**, čím prekonáva ostatné modely podobnej veľkosti, ako **Ministral-3-14B (Precision = 0.3032, Recall = 0.3751 a F1-skóre = 0.3364)** a **Gemma-12B (Precision = 0.4136, Recall = 0.3871 a F1-skóre = 0.3984)**. Modely **Gemma-27B (Precision = 0.4773, Recall = 0.4250 a F1-skóre = 0.4494)** a **LLaVA-13B (Precision = 0.4903, Recall = 0.4122 a F1-skóre = 0.4485)** vykazujú porovnateľný a stabilný výkon, avšak zaostávajú za najlepšie hodnotenými modelmi.

Naopak, menšie alebo odľahčené modely, ako **MiniCPM-V (Precision = 0.4757, Recall = 0.4507, F1-skóre = 0.4605)** a **LLaVA-7B (Precision = 0.4638, Recall = 0.4002, F1-skóre = 0.4298)**, poskytujú mierne nižšiu kvalitu odpovedí, avšak pri nižších výpočtových nárokoch, čo ich predurčuje na použitie v resource-constrained prostrediach. Najslabšie výsledky boli zaznamenané pri modeloch **BakLLaVA (Precision = 0.2078, Recall = 0.2009, F1-skóre = 0.2032)** a **LLaVA-Phi-3 (Precision = 0.0579, Recall = 0.1828, F1-skóre = 0.1116)**, čo poukazuje na ich obmedzenú schopnosť generovať sémanticky konzistentné odpovede v hodnotenom konverzačnom nastavení.



Zároveň však treba zdôrazniť, že v rámci práce bol implementovaný aj **používateľský UI rozhranie**, v ktorom bol nasadený model **Qwen-VL-30B** ako reprezentant modelov s najvyššou kvalitou výstupov. Táto integrácia demonštruje praktickú použiteľnosť vybraného Vision-Language modelu v interaktívnom konverzačnom prostredí a zároveň potvrdzuje vhodnosť modelu **Qwen-VL-30B** pre scenáre, kde je prioritou maximálna kvalita odpovedí.

Táto práca poskytuje systematický prehľad výkonu rôznych **Vision-Language architektúr** a vytvára základ pre informované rozhodovanie pri ich praktickom nasadení.

- [1] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual Instruction Tuning,” in Proc. Advances in Neural Information Processing Systems (NeurIPS), 2023.
- [2] A. Radford et al., “Learning Transferable Visual Models From Natural Language Supervision,” in Proc. International Conference on Machine Learning (ICML), 2021.
- [3] B. Lin, Y. Ye, B. Zhu, J. Cui, M. Ning, P. Jin, and L. Yuan, “Video-LLaVA: Learning United Visual Representation by Alignment Before Projection,” in Proc. 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 5971–5984, 2024.
- [4] S. Hu, Y. Tu, X. Han, C. He, G. Cui, X. Long, Z. Zheng, Y. Fang, Y. Huang, W. Zhao, et al., “MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies,”
- [5] J. Bai, S. Bai, Y. Chu, Z. Cui, K. Dang, X. Deng, Y. Fan, W. Ge, Y. Han, F. Huang, et al., “Qwen Technical Report,” 2023.